

Ramy Lazghab

Ingénieur IA & Machine Learning

LLMs • IA agentique • RAG • Systèmes ML en production

Paris, France • Ouvert à la mobilité • ramy.lazghab@dauphine.eu • +33 7 59 68 79 72

LinkedIn | GitHub | Portfolio

Compétences techniques

Programmation : Python, SQL, Java, JavaScript, C, R

Machine Learning : Deep learning, apprentissage par renforcement, NLP (traitement du langage naturel), transformers, fine-tuning, gradient boosting, explicabilité des modèles (SHAP); PyTorch, TensorFlow, XGBoost, LightGBM

IA générative & LLM : RAG, systèmes multi-agents, évaluation de LLM, prompt engineering; LangChain, LangGraph, Hugging Face, Anthropic API, OpenAI API, MCP, LangSmith

MLOps, Cloud & Données : Docker, Git, MLflow, GCP (Vertex AI, BigQuery, Cloud Run), API REST, PostgreSQL, Neo4j, bases vectorielles (FAISS, Qdrant), Spark, Pandas, NumPy, Streamlit

Expérience professionnelle

Ingénieur IA, stage de fin d'études

Avr. 2026 – aujourd'hui

Relay X, Paris

- **Oracle AI, prévision du risque réglementaire** : prédit si un régulateur restreindra un ingrédient sous 6 ou 18 mois. 1 222 avis scientifiques structurés en un vecteur de 70 variables; ensemble XGBoost + LightGBM, calibration isotonique, explications SHAP. **AUC-ROC 0,948 à 6 mois et 0,914 à 18 mois**, avec validation temporelle stricte sur avis non vus.
- Enrichissement en temps réel via un pipeline LangGraph (Anthropic Claude) à trois nœuds parallèles (PubMed, PubChem, web), restitué en rapport Streamlit; traçage LangSmith.
- **PIF (génération de dossiers)** : pipeline LLM à six agents produisant des Dossiers d'Information Produit conformes au Règlement (CE) 1223/2009, avec sections pilotées par template et validation humaine de l'évaluation de sécurité. **Mis en production** sur la plateforme de production (Next.js, TypeScript, Express, Prisma, PostgreSQL).
- Conception d'un benchmark de référence (5 produits, 203 champs de vérité terrain) utilisé comme boucle de correction sur trois versions : **affirmations non sourcées réduites de 87,5 % à 35,0 %, F1 porté de 81,8 à 89,5, pour 0,13 \$ par dossier**.
- **Magnet (radar réglementaire)** : cascade de recherche à cinq niveaux (SQL d'abord, LLM en dernier recours), rapports sourcés en trois passes. Évalué sur 35 rapports générés à **88,6 % de traçabilité des sources**; 75 tests de sécurité API.

Développeur logiciel, stage

Févr. – Juin 2024

Infinity Management

Plateforme e-learning utilisant le NLP et une analyse de sentiment basée sur BERT; back-end Django REST, front-end React, Docker.

Formation

M2 Science des Données & Intelligence Artificielle

2024 – 2026 (en cours)

Université Paris Dauphine – PSL

Licence en Génie Informatique (IoT)

2021 – 2024

Faculté des Sciences de Tunis

Projets sélectionnés

- **TelecomPlus** : support client multi-agents (RAG + routage SQL), évaluation LLM-as-a-Judge, traçage Langfuse & MLflow. *LangChain, LangGraph, FAISS, PostgreSQL*
- **RAGenius** : assistant de recherche IA répondant à des questions sur PDF et CSV par recherche sémantique. *LangChain, Hugging Face, FAISS*
- **Movie Recommender** : système de recommandation de bout en bout sur GCP, exposé en API REST. *BigQuery ML, Vertex AI, Cloud Run*
- **Prédiction d'Alzheimer** : ensemble XGBoost et deep learning pour la détection précoce; SHAP pour l'interprétabilité clinique. *PyTorch, XGBoost, SHAP*

Certifications & Distinctions

- **Certifications** : LangChain Academy; Google Cloud, BigQuery ML
- **3^e place**, RAISE Summit AI Hackathon Paris; **Lauréat**, Hack for Good (MoodSync); EY Hack for Smart Insurance; IEEE Xtreme 15.0/16.0; membre IEEE, ITLAB & AIESEC
- **Langues** : Anglais, courant (IELTS) | Français, professionnel